

Федеральное государственное автономное образовательное учреждение
высшего образования
**«Московский авиационный институт
(национальный исследовательский университет)»**

ЛАБОРАТОРНАЯ РАБОТА № 1

«Добыча корпуса документов»

по дисциплине «Информационный поиск»

<i>Студент:</i>	Кунавин К. В.
<i>Группа:</i>	М8О-403Б-23
Проверил:	Кухтичев А. А.
Дата:	21.09.2026
Оценка:	

Москва — 2026

1. Задание

Цель работы — проанализировать корпус документов, который будет использоваться в последующих лабораторных работах по информационному поиску.

В рамках лабораторной работы необходимо:

- определить тематику будущего корпуса;
- выбрать не менее двух источников документов;
- скачать примеры документов и исследовать формат их представления;
- изучить разметку, структуру текста и дополнительную метainформацию;
- реализовать выделение основного текста;
- привести документы различных источников к единому представлению;
- исследовать существующие поисковые системы для выбранных источников;
- выполнить несколько поисковых запросов и выявить недостатки получаемой выдачи;
- получить статистические характеристики примеров документов: размер исходных данных, размер выделенного текста, количество документов и средние значения.

2. Краткое описание метода решения

В качестве тематики корпуса были выбраны научные публикации по психологии, образованию и исследованиям поведения человека.

В качестве источников документов используются:

1. PubMed Central (PMC) — полнотекстовый архив научных публикаций.
2. ERIC — информационная система, специализирующаяся на публикациях в области образования и образовательной психологии.

Для каждого источника был выбран пример научной публикации. Документы были сохранены локально и проанализированы с точки зрения структуры исходных данных, наличия метainформации и возможности выделения основного текста.

Для PMC исходные данные были получены через OAI-PMH в формате XML. Внутри OAI-PMH статья представлена в формате JATS. Документ содержит структурированные метаданные, аннотацию и основной текст статьи.

Для ERIC полный текст публикации представлен PDF-файлом, а метаданные публикации хранятся отдельно. Поэтому обработка ERIC состоит из двух частей: чтения метаданных и извлечения текста из PDF.

Для автоматизации обработки были реализованы два Python-скрипта. Скрипт обработки PMC использует стандартный модуль `xml.etree.ElementTree`, а для извлечения текста из PDF ERIC используется библиотека `pypdf`.

После обработки документы обоих источников приводятся к единому JSON-представлению со следующими полями:

```
id
source
title
authors
publication_date
keywords
abstract
text
```

Такое представление позволяет в дальнейшем обрабатывать документы различных источников единым способом.

2.1. Источники данных

PubMed Central:

```
https://pmc.ncbi.nlm.nih.gov/articles/PMC8935530/
https://pmc.ncbi.nlm.nih.gov/api/oai/v1/mh/
```

ERIC:

```
https://eric.ed.gov/?id=EJ854309
https://files.eric.ed.gov/fulltext/EJ854309.pdf
```

3. Журнал выполнения задания

На первом этапе была выбрана тематика будущего корпуса — научные публикации, связанные с психологией, образованием и поведением человека. После анализа возможных источников для работы были выбраны PubMed Central и ERIC.

Для PMC был найден механизм получения исходной разметки публикации через OAI-PMH. В качестве примера использована публикация с идентификатором PMC8935530. Полученный документ имеет XML-разметку JATS и содержит структурированные метаданные и полный текст статьи. В XML присутствуют идентификаторы PMCID, PMID и DOI, информация об авторах, дате публикации, аннотации и ключевых словах.

Был разработан скрипт `extract_pmc.py`, который извлекает PMCID, название статьи, список авторов, дату публикации, ключевые слова, аннотацию и содержимое `<body>`. Полученная информация сохраняется в JSON.

Для ERIC была выбрана публикация EJ854309. Полный текст представлен PDF-документом объёмом 13 страниц. Для обработки был разработан скрипт `extract_eric.py`. Он загружает метаданные из JSON, извлекает текст всех страниц PDF с помощью `pypdf`, удаляет лишние пробелы и создаёт документ того же формата, который применяется для PMC.

Для автоматического получения количественных характеристик был реализован скрипт `statistics.py`. Он определяет размер исходных документов, объём выделенного UTF-8 текста, количество символов и слов, а также вычисляет суммарные и средние значения.

При попытке получить HTML-страницу ERIC с помощью `curl` соединение было сброшено. Поэтому полный текст публикации был получен напрямую в формате PDF, а метаданные сохранены отдельно.

Во время проверки воспроизводимости проекта было обнаружено, что библиотека `pypdf` была установлена только в глобальной среде Python и отсутствовала в созданном виртуальном окружении. Для решения проблемы

был создан файл requirements.txt, содержащий необходимую версию зависимости.

После этого был создан единый скрипт run_lab01.py, который последовательно запускает обработку PMC, обработку ERIC, расчёт статистики и автоматические тесты. Итоговый запуск из виртуального окружения завершился успешно.

4. План тестирования

Цель тестирования — проверить корректность выделения данных из исходных документов PubMed Central и ERIC, а также приведение документов разных источников к единому формату.

№	Проверка	Ожидаемый результат
1	Проверка идентификатора PMC	PMC8935530
2	Проверка идентификатора ERIC	EJ854309
3	Проверка названия PMC	Поле title не пустое
4	Проверка названия ERIC	Поле title не пустое
5	Проверка авторов PMC	Не менее одного автора
6	Проверка авторов ERIC	Не менее одного автора
7	Проверка основного текста PMC	Более 1000 символов
8	Проверка основного текста ERIC	Более 1000 символов
9	Проверка единого формата	Наличие всех обязательных полей

Автоматические тесты реализованы на основе стандартного модуля unittest. Результат прогона тестового плана сохраняется отдельно в файле results/tests.txt.

5. Результаты

5.1. Анализ PubMed Central

В качестве примера документа PubMed Central использована статья «Pathways to Student Motivation: A Meta-Analysis of Antecedents of Autonomous and Controlled Motivations». Идентификатор документа — PMC8935530.

Документ получен через OAI-PMH в формате XML. Непосредственно статья представлена в формате JATS. Корневым элементом статьи является <article>. Для рассматриваемого документа указаны язык en и тип research-article.

Структура статьи включает:

- <front> — метаданные;
- <body> — основной текст;
- <back> — дополнительная информация, примечания и список литературы.

В <front> находятся название публикации, авторы, идентификаторы, дата публикации, аннотация и ключевые слова. В <body> текст разделён на секции, заголовки и абзацы. В <back> располагаются дополнительные сведения и список литературы.

Для поискового корпуса из документа сохраняются идентификатор, название, авторы, дата публикации, аннотация, ключевые слова, заголовки разделов и основной текст. Техническая OAI-PMH-разметка, XML-атрибуты, информация о лицензии и другие служебные элементы не являются частью индексируемого текста.




Рисунок 1 — Пример публикации в PubMed Central

5.2. Анализ ERIC

В качестве примера документа ERIC использована публикация «The Causal Ordering of Self-Concept and Academic Motivation and Its Effect on Academic Achievement». Идентификатор документа — EJ854309.

В отличие от PMC, полный текст и метаданные ERIC представлены раздельно. Метаданные содержат идентификатор, название, авторов, дату публикации, язык, дескрипторы и количество страниц. Основной текст представлен PDF-файлом.

При извлечении текста из PDF необходимо учитывать появление дополнительного шума: номеров страниц, колонтитулов, подписей к изображениям, таблиц и списка литературы. В текущей реализации текст извлекается постранично, после чего удаляются лишние пробелы.

После обработки документ ERIC приводится к тому же JSON-представлению, что и документ PMC, что позволяет использовать оба источника в едином будущем индексе.

5.3. Анализ существующих поисковых систем

Для обоих выбранных источников существуют готовые поисковые системы, поэтому выбранные источники пригодны для дальнейшего формирования корпуса. Для PMC использовался встроенный полнотекстовый поиск PubMed Central, для ERIC — поисковая система ERIC. Для анализа использовались три запроса различной степени конкретности:

- student motivation
- student motivation self determination
- teacher autonomy support student motivation

Запрос	PMC	ERIC
student motivation	401 253	60 058
student motivation self determination	82 022	18 653
teacher autonomy support student motivation	23 720	81 606

В PMC широкий запрос student motivation возвращает большое число документов и заметный тематический шум. Например, среди первых результатов присутствует статья о мотивации добровольцев во время эпидемии Эболы, которая не относится к академической мотивации студентов. При добавлении уточняющих терминов объём выдачи уменьшается, а верхние результаты в целом становятся более релевантными.

ERIC как специализированная образовательная база уже на широком запросе демонстрирует более тематически однородную верхнюю часть выдачи. Однако количество документов не всегда монотонно уменьшается при добавлении терминов: третий запрос дал больше результатов, чем два предыдущих. Следовательно, поведение поиска ERIC нельзя интерпретировать как простое логическое пересечение всех введённых слов.

Метрики качества собственной поисковой системы (P, DCG, NDCG, ERR) в данной работе не рассчитывались, поскольку лабораторная работа № 1 посвящена анализу корпуса и существующих поисковых систем, а

собственный поисковый механизм ещё не реализован. Оценка выдачи на этом этапе носит качественный характер.




Рисунок 2 — Выдача PMC по запросу «student motivation»




Рисунок 3 — Выдача PMC по запросу «teacher autonomy support student motivation»

ERIC - Search Results

Collection Thesaurus

student motivation

Peer reviewed only Full text available on ERIC

Showing 1 to 15 of 60,058 results Save | Export

Interlinking Teachers' Beliefs and Motivational Practices: A Cross-Country Examination of the Relationship with Students' Motivation in Mathematics
Jelena Radišić, Nils Buchholz, Aleksandar Baucal, Kajsa Yang Hansen, Xin Liu, Francisco Peixoto, Anu Laine, Ali Leijen – ZDM: Mathematics Education, 2026

Building on previous research into teachers' beliefs and practices in mathematics and their effects on students' motivation, grounded in the situated-expectancy value framework, we combine person- and variable-centred approaches to examine changes in students' motivation for mathematics as they transition to middle school. Using longitudinal data...

Descriptors: Teacher Attitudes, Beliefs, Student Motivation, Teacher Student Relationship

Factors Influencing Nursing and Health Techniques Students' Motivation Using Learning Management Systems: A Multicentre Cross-Sectional Study
Aziz Naciri, Mohamed Radid, Lahoucine Ben Yahya, Ghizlane Chemsi – Journal of Learning for Development, 2026

Distance learning has become an effective alternative to face-to-face learning in many fields, including the health professions. This study aims to identify the factors influencing nursing and health techniques students' motivation using learning management systems. A multicentre cross-sectional study was conducted with students from Moroccan...

Descriptors: Nursing Students, Allied Health Occupations Education, College Students, Student Motivation

The Impact of Constructivist Learning Environment on Students' Motivation in Primary School
Bilma Çobukoğlu – Bulgarian Comparative Education Society, 2025

Learning in a constructivist environment has the potential to help students' motivation in primary school. This study aims to present the impact of the constructivist learning environment on students' motivation in primary school and specify which aspects of the constructivist learning environment are related to the types of students' motivation.

Descriptors: Constructivism (Learning), Student Motivation, Learning Motivation, Elementary School Students

University Students' Motivation to Study and Satisfaction with the Academic Environment
Andreea Lukács, Alin Kárpáti – Journal of Further and Higher Education, 2026

This study investigates the factors influencing university students' motivation to study and their satisfaction with the academic environment. Drawing on Self-Determination Theory, the study explores the interplay between intrinsic and extrinsic motivations, as well as the impact of satisfaction on students' motivation. An exploratory quantitative...

Descriptors: Student Motivation, Student Satisfaction, Educational Environment, Foreign Countries

Student-Perceived Supervisor Motivation and Grade Pressure as Predictors of German Psychology Students' Thesis Motivation

Рисунок 4 — Выдача ERIC по запросу «student motivation»

ERIC - Search Results

Collection Thesaurus

teacher autonomy support student m

Peer reviewed only Full text available on ERIC

Showing 1 to 15 of 81,606 results Save | Export

Dynamics of Teacher Autonomy Support in Early Adolescence: Feedforward and Feedback Effects with Students' Autonomy, Competence, Relatedness, and Engagement
Nicolette P. Rickert, Julia S. Dancs, Ellen A. Skinner – European Journal of Psychology of Education, 2024

This study examined the reciprocal dynamics of teacher autonomy support with student motivation and engagement during late elementary and early middle school. A total of 861 students in grades 5-7 reported on three components of teacher autonomy support (choice, relevance, and respect), as well as their own engagement and self-system processes.

Descriptors: Feedback (Response), Personal Autonomy, Competence, Learner Engagement

Autonomy Support and Motivation in Physical Education: A Comparison of Teacher and Student Perspectives
Aylin Arık, Gözde Ertauran – International Journal of Contemporary Educational Research, 2023

The aim in this study was to identify predictors of teachers' and students' motivation and autonomy support in physical education. Ninety-four physical education teachers (26 female, 68 male) and 2127 students (1093 boys, 1026 girls, and 8 no gender specified) from 56 (42 public, 14 private) high schools all voluntarily participated in the study...

Descriptors: Personal Autonomy, Physical Education, Teacher Attitudes, Physical Education Teachers

Teachers' Motivating Style and Students' Motivation and Engagement in STEM: The Relationship between Three Key Educational Concepts
De Loof, Haydée, Struyf, Annemie, Boeve-de Pauw, Jelle, Van Petegem, Peter – Research in Science Education, 2021

A key theme in the science education literature concerns the reluctance of students to participate in Science, Technology, Engineering, and Mathematics (STEM). Self-determination theory (SDT) states that social factors in an educational setting, such as teachers' motivating style, can influence students' motivation and engagement. This paper...

Descriptors: Teaching Styles, Motivation Techniques, Student Motivation, Personal Autonomy

Exploring the Relationships among Teacher Autonomy Support, Intrinsic Motivation, Academic Resilience, Learning Engagement, and Well-Being: A Mixed Methods Study
Yafen Shi, Mengjin Chen, Yantao Wei, Xingang Zhang, Ke Zhu – European Journal of Education, 2026

This sequential explanatory mixed-methods study explored how teachers' autonomy support influences students' learning engagement and well-being in online learning environments, with intrinsic motivation and academic resilience as mediators. Quantitative data were gathered through surveys of 990 university students, followed by in-depth qualitative...

Descriptors: Teacher Student Relationship, Professional Autonomy, Learner Engagement, Well Being

Associations between Parents' and Teachers' Autonomy Support and the Bifactor Model of Academic Motivation: A

Рисунок 5 — Выдача ERIC по запросу «teacher autonomy support student motivation»

5.4. Статистическая информация

Показатель	PMC8935530	EJ854309
Размер исходного документа	161.11 KB	209.99 KB
Размер выделенного текста	54.41 KB	46.95 KB
Количество символов	55 544	47 985
Количество слов	8 151	6 658

Показатель	Значение
Количество примеров	2
Общий размер исходных документов	371.10 KB
Общий размер выделенного текста	101.36 KB
Средний размер исходного документа	185.55 KB
Средний объём выделенного текста	50.68 KB

Полученные результаты относятся к исследованным примерам документов, а не ко всему будущему корпусу. Массовое получение корпуса будет выполняться на следующих этапах курса.

5.5. Результаты тестирования и воспроизводимость

Для выполнения плана тестирования реализовано 9 автоматических тестов. Все тесты завершились успешно.

```
Ran 9 tests in 0.004s
```

OK

Для воспроизводимого запуска проекта используется файл requirements.txt и единый скрипт run_lab01.py. Запуск из корневой директории проекта выполняется командами:

```
python -m pip install -r lab01/requirements.txt
python lab01/run_lab01.py
```

Скрипт последовательно обрабатывает пример PMC, обрабатывает пример ERIC, рассчитывает статистику и запускает автоматические тесты.

6. Выводы

В ходе лабораторной работы был проведён анализ источников документов для будущего поискового корпуса научных публикаций по психологии, образованию и исследованиям поведения человека.

Было исследовано два источника — PubMed Central и ERIC. Они существенно отличаются способом представления данных. PMC предоставляет структурированный XML в формате JATS, благодаря чему метаданные и основной текст могут быть выделены непосредственно из разметки. В ERIC метаданные и полный текст могут храниться отдельно, а текст приходится извлекать из PDF.

Для обоих источников была реализована автоматическая обработка и приведение документов к единому JSON-формату. Это создаёт основу для совместной индексации документов в последующих лабораторных работах.

Анализ встроенных поисковых систем PMC и ERIC показал, что наличие терминов запроса в документе не гарантирует его тематическую релевантность. Конкретизация запроса в PMC уменьшает количество найденных документов и улучшает верхнюю часть выдачи, однако полностью тематический шум не исчезает. ERIC благодаря своей специализации на образовательных публикациях в целом предоставляет более однородную тематическую выдачу, но интерпретация сложных запросов поисковой системой не всегда очевидна.

Разработанные программы успешно прошли 9 автоматических тестов. Воспроизводимый запуск обеспечен через requirements.txt и run_lab01.py.

Основным ограничением выполненной работы является то, что исследовались отдельные примеры документов, а не полный корпус. Кроме того, при извлечении текста из PDF ERIC в документ могут попадать колонтитулы, номера страниц и элементы списка литературы. При дальнейшем развитии проекта необходимо реализовать массовую загрузку документов, более качественную очистку PDF и автоматическую нормализацию метаданных.

Полученные результаты позволяют использовать выбранные источники для формирования корпуса и выполнения последующих лабораторных работ по информационному поиску.

7. Репозиторий

Исходный код, примеры документов, результаты обработки, автотесты и отчёт размещены в репозитории GitHub по адресу:

<https://github.com/Fasko1/MAI-IR/tree/main/lab01>



Рисунок — QR-код для перехода к репозиторию лабораторной работы